Simulación determinística vs. estocástica: impacto en la interpretación y la incertidumbre

Alejandro Padilla[1]
[1]Facultad de la Energía, las Industrias y los Recursos Naturales No Renovables, Universidad Nacional de Loja, Loja, Ecuador
alejandro.padilla@unl.edu.ec

***Resumen*—Este ensayo tiene como objetivo analizar cómo la elección entre simulación determinística y estocástica afecta la interpretación de los resultados y el tratamiento de su incertidumbre. El problema, según la literatura revisada, es que la mayoría de las simulaciones son determinísticas aunque los sistemas reales presentan variabilidad, y que los intervalos de confianza habituales no consideran la incertidumbre de los parámetros de entrada. Se realizó una búsqueda documental orientada a Scopus, IEEE Xplore y ACM Digital Library con los términos deterministic vs stochastic simulation y uncertainty quantification, y se seleccionaron siete artículos revisados por pares, publicados entre 2000 y 2024, que comparan ambos enfoques o proponen métodos para cuantificar la incertidumbre. Los conceptos se aplicaron a un ejemplo propio de una cola M/M/1. Los trabajos comparativos coinciden en que el modelo determinístico omite efectos que dependen del azar, y los metodológicos proponen reportar la salida estocástica con intervalos que incluyan también la incertidumbre de los parámetros de entrada. En el ejemplo, la versión determinística predice una espera nula, mientras la estocástica estima cerca de 4.6 minutos. Como resultado, el tipo de modelo define qué preguntas pueden responderse.**

***Palabras clave*—cuantificación de incertidumbre; incertidumbre de entrada; modelos estocásticos; simulación determinística; teoría de colas.**

I. Introducción

Roy y Oberkampf señalan que la mayoría de las simulaciones científicas son determinísticas, mientras que las aplicaciones de ingeniería están cargadas de incertidumbre por la variabilidad de los materiales, las condiciones iniciales y el entorno del sistema [1]. La elección del tipo de modelo cambia los resultados: en modelos epidémicos, la versión determinística predice persistencia o extinción según el valor de R0, mientras que la estocástica predice extinción segura para cualquier R0 [2]. Esa diferencia también afecta las decisiones. Flaig y Houy mostraron que el modelo determinístico no considera la extinción temprana de una epidemia y, por eso, lleva a elegir una política de vacunación distinta de la que elige el modelo estocástico [3]. A esto se suma la incertidumbre de entrada: las distribuciones de entrada no se conocen con certeza [4], y los intervalos de confianza estándar de simulación no consideran que sus parámetros se estimaron con datos reales finitos [5].

El objetivo de este ensayo es analizar cómo la elección entre simulación determinística y estocástica afecta la interpretación de los resultados y su incertidumbre. Para ello se revisan siete artículos indexados en Scopus e IEEE Xplore, se comparan sus hallazgos y se simula una cola M/M/1 en versión determinística, estocástica con 10 réplicas y con incertidumbre en la tasa de llegada. Este ensayo se estructura de la siguiente manera: la sección II presenta los conceptos clave y la estrategia de búsqueda; la sección III compara los trabajos y aplica los conceptos a la cola M/M/1; la sección IV concluye.

II. Marco teórico y metodología

A. Conceptos clave

Un modelo determinístico no contiene componentes aleatorios: dadas las entradas, la salida queda determinada. Un modelo estocástico incluye al menos una entrada aleatoria, por lo que su salida también es aleatoria y cada corrida es solo una estimación de las características del modelo [6]. Por eso la salida estocástica se analiza con réplicas independientes e intervalos de confianza, no con una corrida aislada [6].

Roy y Oberkampf distinguen dos tipos de incertidumbre [1]. La aleatoria es la variación inherente de una cantidad y puede describirse con una distribución de probabilidad; la epistémica proviene de la falta de conocimiento y, en su marco, se representa con intervalos sin distribución asumida. A ellas se suman los errores numéricos y la incertidumbre por la forma del modelo, que se estiman mediante verificación y validación.

En la simulación de eventos discretos interesa en particular la incertidumbre de entrada: no conocer las distribuciones reales que alimentan el modelo, como los tiempos entre llegadas y de servicio de una cola [4]. Cuando esas distribuciones se ajustan con datos finitos, la estimación de salida contiene a la vez error de simulación e incertidumbre de entrada [7].

B. Estrategia de búsqueda

La búsqueda se realizó en octubre de 2026 y se orientó a Scopus, IEEE Xplore y ACM Digital Library. Se usaron las palabras clave del tema, deterministic vs stochastic simulation y uncertainty quantification, combinadas con input uncertainty, output analysis y stochastic model comparison mediante los operadores AND y OR. Se filtraron artículos de revista y de congreso en inglés, sin restricción de año para incluir trabajos fundacionales.

Los criterios de selección fueron los siguientes:

1) Trabajo revisado por pares e indexado en al menos una de las tres bases.
2) Que compare versiones determinística y estocástica de un mismo modelo, o que proponga un método para cuantificar la incertidumbre de la salida de una simulación.
3) Que tenga un DOI verificable.

Se retuvieron siete artículos: dos comparativos [2], [3], uno conceptual sobre tipos de incertidumbre [1] y cuatro metodológicos sobre incertidumbre en simulación estocástica [4], [5], [7], [8]. Ninguno de los artículos retenidos proviene de ACM Digital Library. Como apoyo para las fórmulas de colas se usó además el texto de Law [6].

III. Desarrollo y análisis

La Tabla 1 resume los siete trabajos revisados según el modelo que usan, la incertidumbre que tratan y su hallazgo principal.

Tabla 1. Comparación de los trabajos revisados

Trabajo	Modelo y dominio	Incertidumbre tratada	Hallazgo principal
Allen y Burgin [2]	determinístico y estocástico, epidemias SIS y SIR	aleatoria, con cadenas de Markov	en el estocástico la extinción es segura para cualquier R0
Flaig y Houy [3]	determinístico y estocástico, epidemia SIR	aleatoria y de parámetros	el modelo usado cambia la política elegida
Roy y Oberkampf [1]	marco general, computación científica	aleatoria y epistémica por separado	la incertidumbre total incluye error numérico y forma del modelo
Song, Nelson y Pegden [4]	estocástico, colas y otros sistemas	de entrada	define el efecto de no conocer las distribuciones verdaderas
Barton, Nelson y Xie [5]	estocástico	de entrada y de simulación	IC por bootstrap asistido por metamodelo
Xie, Nelson y Barton [7]	estocástico	de entrada y de simulación, bayesiana	intervalo de credibilidad con proceso gaussiano
Jeon et al. [8]	estocástico	de salida	agrupamiento en lotes como recurso general

A. Coincidencias: lo que el modelo determinístico no ve

Los dos trabajos comparativos coinciden en que el modelo determinístico no reproduce la extinción que sí aparece en su versión estocástica [2], [3]. Allen y Burgin muestran que, en los modelos epidémicos determinísticos, el número reproductivo básico R0 decide si la enfermedad persiste o desaparece, mientras que en sus contrapartes estocásticas la extinción es segura para cualquier R0, aunque pueda tardar mucho [2].

Ambos enfoques se acercan bajo una condición: si se condiciona a que la epidemia no se extinga y R0 >1, la media de la distribución cuasiestacionaria coincide con el equilibrio endémico determinístico [2]. Flaig y Houy abordan la misma diferencia desde la toma de decisiones: el modelo determinístico no considera la extinción temprana, y eso lo lleva a recomendar una política de vacunación distinta de la que elige el modelo estocástico [3].

De esta comparación se desprende que el modelo determinístico responde bien a la pregunta de qué ocurre en promedio, pero no a qué tan probable es un resultado extremo. Si la decisión depende de los extremos de la distribución, el valor medio no basta.

B. Contradicciones y matices

El matiz principal es si el modelo estocástico siempre es preferible. Flaig y Houy encontraron que el mejor desempeño se obtiene con el modelo estocástico, parámetros conocidos y muestras grandes, pero que con muestras pequeñas el modelo determinístico puede superarlo por efectos estocásticos [3]. En su ejemplo, resolver la incertidumbre de los parámetros aportó más que cambiar al modelo estocástico, aunque los autores advierten que no esperan que esto se cumpla siempre.

Este resultado conecta con la literatura de incertidumbre de entrada. Song, Nelson y Pegden definen la incertidumbre de entrada como el efecto de no conocer las distribuciones verdaderas que alimentan la simulación [4], y Barton, Nelson y Xie muestran que los intervalos de confianza estándar de simulación no consideran esa incertidumbre [5]. Es decir, un modelo estocástico bien replicado puede transmitir una precisión falsa si sus parámetros fueron estimados con pocos datos.

Los métodos propuestos también difieren en su interpretación. Barton, Nelson y Xie construyen intervalos de confianza frecuentistas mediante bootstrap asistido por un metamodelo [5]. Xie, Nelson y Barton usan un enfoque bayesiano que entrega un intervalo de credibilidad, y aclaran que este se interpreta de forma distinta a los intervalos de confianza [7]. Jeon et al. proponen el agrupamiento en lotes como recurso general para cuantificar la incertidumbre usando solo los datos de salida [8].

Roy y Oberkampf separan de forma rigurosa la incertidumbre aleatoria de la epistémica y representan la segunda con intervalos sin distribución asumida [1]. Esto contrasta con el enfoque bayesiano, que sí asigna una distribución posterior a los parámetros de entrada [7]. Para un curso de simulación, la consecuencia práctica es que todo intervalo reportado debe aclarar qué incertidumbre incluye.

C. Ejemplo aplicado: cola M/M/1

Para aplicar estos conceptos se simuló una cola de un servidor con tasa de llegada $\lambda = 0.8$ clientes/min y tasa de servicio $\mu = 1$ cliente/min, es decir, una utilización $\rho = 0.8$. Cada corrida atiende 2000 clientes partiendo del sistema vacío, y la espera en cola se calcula con la recursión de Lindley. El valor teórico de referencia es [6]:

$$W_q = \frac{\lambda}{\mu(\mu - \lambda)} = \frac{0.8}{1 \cdot 0.2} = 4.0 \text{ min}$$

Tabla 2. Espera media en cola Wq según el tipo de modelo

Modelo	Supuesto	Wq obtenido
Determinístico	llegadas cada 1.25 min y servicio de 1 min exactos	0 min
Estocástico, una réplica	tiempos exponenciales	entre 2.64 y 7.24 min según la réplica
Estocástico, 10 réplicas	tiempos exponenciales	media 4.57 min, IC 95 % [3.48, 5.66]
Estocástico con incertidumbre de entrada	λ estimado con 50 datos ($\hat{\lambda} = 0.766$)	entre 1.53 y 20.97 min (percentiles 2.5 y 97.5)

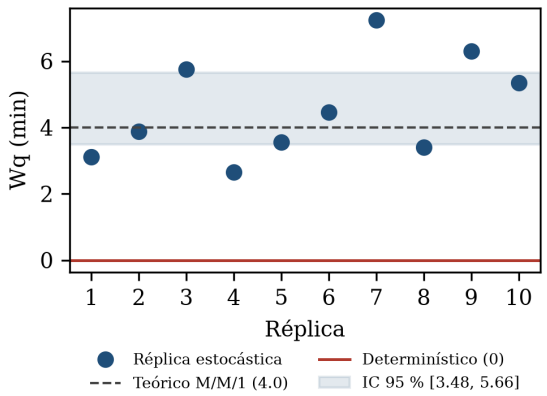


Figura 1. Espera media en cola por réplica, con su IC 95 %, frente al modelo determinístico y al valor teórico

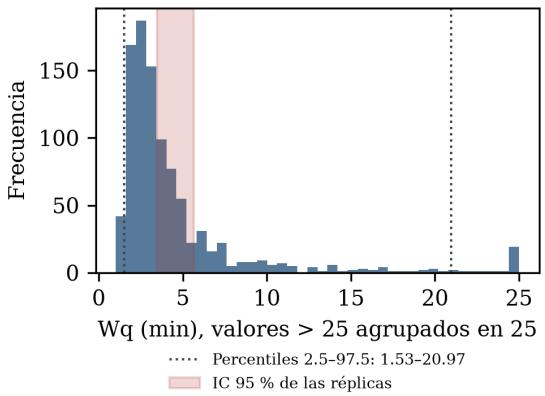


Figura 2. Distribución de Wq al remuestrear la tasa de llegada estimada con 50 datos

Según la Tabla 2, la versión determinística predice que nadie espera, porque cada cliente llega después de que el anterior terminó. El resultado es exacto para ese modelo, pero engañoso para el sistema real: la congestión de una cola nace de la variabilidad, que el modelo eliminó. Es el mismo tipo de omisión que señalan los trabajos comparativos, donde el modelo determinístico pierde los efectos que dependen del azar [3].

En la versión estocástica, una sola réplica puede dar 2.64 o 7.24 minutos, y reportar cualquiera de ellas como la respuesta sería un error de interpretación. Con 10 réplicas, el intervalo de confianza al 95 % [3.48, 5.66] contiene el valor teórico de 4.0 minutos; esa es la forma correcta de reportar el resultado [6]. La Figura 1 muestra la dispersión de las réplicas frente a los valores determinístico y teórico.

El tercer caso muestra lo que el intervalo anterior no incluye. Si λ se estima con 50 tiempos entre llegadas observados y se remuestrea esa muestra 1000 veces, calculando Wq con la fórmula anterior en cada caso, las esperas van de 1.53 a 20.97 minutos, y en el 2.1 % de los remuestreos λ supera a μ y la cola se vuelve inestable.

Esta dispersión es la incertidumbre de entrada descrita por Barton, Nelson y Xie [5]. La Figura 2 compara la distribución resultante con el IC 95 % de las réplicas.

Tabla 3. Espera media en cola Wq según la carga del sistema

ρ	Determinístico	Teórico	Estocástico, 10 réplicas	IC 95 %
0.5	0 min	1.0 min	1.04 min	[0.93, 1.15]
0.8	0 min	4.0 min	4.57 min	[3.48, 5.66]
0.9	0 min	9.0 min	10.32 min	[6.78, 13.86]

Para ver cómo cambia la brecha con la carga, se repitió el experimento con $\lambda = 0.5$ y $\lambda = 0.9$ clientes/min y 10 réplicas (Tabla 3). El modelo determinístico predice espera nula en los tres casos. En cambio, el valor teórico pasa de 1.0 a 9.0 minutos y la semiamplitud relativa del intervalo crece de 11 % a 34 %: con más carga, el modelo determinístico se aleja más y el estocástico pierde precisión.

D. *Réplicas necesarias para una precisión dada*

Una semiamplitud de 34 % no permite comparar escenarios con confianza. A partir de la varianza de una corrida piloto puede estimarse cuántas réplicas hacen falta para una precisión dada [6]. Como la semiamplitud decrece con la raíz del número de réplicas, se usó $n = n_0(h_0/h)^2$, con $n_0 = 10$ réplicas piloto, h_0 la semiamplitud relativa obtenida y $h = 10\,\%$ como objetivo (Tabla 4).

Tabla 4. Réplicas necesarias para una semiamplitud de 10 % de la media

ρ	Semiamplitud con 10 réplicas	Réplicas necesarias	IC 95 % final	Teórico
0.5	11 %	12	[0.94, 1.12]	1.0 min
0.8	24 %	57	[3.88, 4.44]	4.0 min
0.9	34 %	118	[8.30, 9.70]	9.0 min

Al correr esas réplicas, los tres intervalos quedaron por debajo del objetivo (8.9 %, 6.8 % y 7.8 %) y contienen el valor teórico, como muestra la Figura 3. Con 57 réplicas, la media para $\rho = 0.8$ bajó de 4.57 a 4.16 minutos: parte de la diferencia inicial con el valor teórico era ruido de pocas réplicas.

El costo crece rápido con la carga: el sistema con $\rho = 0.9$ necesitó casi diez veces más réplicas que el de $\rho = 0.5$. La incertidumbre de la salida, por lo tanto, no es una propiedad fija del modelo, sino que depende del sistema simulado y del esfuerzo de simulación invertido.

E. *Implicaciones para la interpretación*

El ejemplo ordena los hallazgos de la literatura en tres niveles. El modelo determinístico sirve para verificar la lógica del modelo y para sistemas con poca variabilidad, pero no para estimar congestión. El modelo estocástico exige réplicas e intervalos de confianza. Y cuando las entradas provienen de datos limitados, el intervalo debe incorporar la incertidumbre

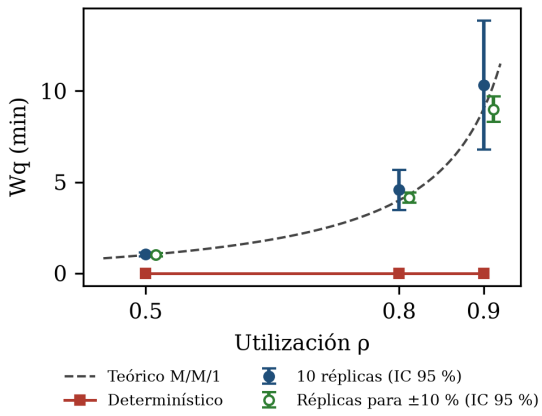


Figura 3. Wq según la utilización: modelo determinístico, valor teórico y estimaciones estocásticas con 10 réplicas y con las réplicas necesarias para ±10 %

de entrada, que en este ejemplo es mucho mayor que el error de simulación.

F. Limitaciones del ejemplo

El ejemplo tiene tres limitaciones. Cada corrida parte con el sistema vacío y no descarta un periodo de calentamiento, lo que puede sesgar la media hacia abajo, sobre todo con alta utilización [6]. Además, los tres escenarios de carga usan la misma semilla, por lo que sus resultados están correlacionados entre sí y no son muestras independientes.

Por último, en el caso con incertidumbre de entrada, Wq se calculó con la fórmula analítica en cada remuestreo en lugar de simular. Eso fue posible porque la cola M/M/1 tiene solución exacta; en un sistema sin fórmula habría que reemplazarla por un metamodelo, como en el bootstrap asistido por metamodelo de Barton, Nelson y Xie [5].

IV. Conclusiones

La elección entre simulación determinística y estocástica define qué se puede afirmar con los resultados. El modelo determinístico entrega el comportamiento medio, pero omite efectos que dependen del azar, como la extinción temprana de una epidemia o la espera en una cola cargada. El modelo estocástico los captura, a cambio de que sus resultados se interpreten como estimaciones con incertidumbre y no como valores únicos.

La literatura revisada coincide en que esa incertidumbre tiene dos componentes, el error de simulación y la incertidumbre de entrada, y difiere en cómo combinarlos e interpretarlos. Como trabajo futuro se propone extender el ejemplo M/M/1 con los métodos de bootstrap asistido por metamodelo o bayesianos revisados, y aplicarlo a un sistema con datos reales, como una línea de producción.

Referencias

[1] C. J. Roy y W. L. Oberkampf, «A comprehensive framework for verification, validation, and uncertainty quantification in scientific computing,» *Comput. Methods Appl. Mech. Eng.*, vol. 200, n.º 25–28, págs. 2131-2144, jun. de 2011. DOI: 10.1016/j.cma.2011.03.016

[2] L. J. S. Allen y A. M. Burgin, «Comparison of deterministic and stochastic SIS and SIR models in discrete time,» *Math. Biosci.*, vol. 163, n.º 1, págs. 1-33, ene. de 2000. DOI: 10.1016/S0025-5564(99)00047-4

[3] J. Flaig y N. Houy, «Disease X epidemic control using a stochastic model and a deterministic approximation: Performance comparison with and without parameter uncertainties,» *Comput. Methods Programs Biomed.*, vol. 249, pág. 108 136, jun. de 2024. DOI: 10.1016/j.cmpb.2024.108136

[4] E. Song, B. L. Nelson y C. D. Pegden, «Advanced tutorial: Input uncertainty quantification,» en *Proc. Winter Simul. Conf. (WSC)*, IEEE, dic. de 2014, págs. 162-176. DOI: 10.1109/WSC.2014.7019886

[5] R. R. Barton, B. L. Nelson y W. Xie, «Quantifying Input Uncertainty via Simulation Confidence Intervals,» *INFORMS J. Comput.*, vol. 26, n.º 1, págs. 74-87, feb. de 2014. DOI: 10.1287/ijoc.2013.0548

[6] A. M. Law, *Simulation Modeling and Analysis*, 5.ª ed. New York, NY, USA: McGraw-Hill Education, 2015, ISBN: 978-0-07-340132-4.

[7] W. Xie, B. L. Nelson y R. R. Barton, «A Bayesian Framework for Quantifying Uncertainty in Stochastic Simulation,» *Oper. Res.*, vol. 62, n.º 6, págs. 1439-1452, dic. de 2014. DOI: 10.1287/opre.2014.1316

[8] Y. Jeon, Y. Chu, R. Pasupathy y S. Shashaani, «Uncertainty quantification using simulation output: batching as an inferential device,» *J. Simul.*, vol. 19, n.º 6, págs. 674-693, dic. de 2024. DOI: 10.1080/17477778.2024.2425311