La caja rápida como cola M/M/1

Teoría, código y gráficas, en el mismo orden en que se explican. Semilla 42, 20 000 minutos simulados, λ = 2.0 · 2.5 · 2.9 y μ = 3.0 clientes/min.

Cómo usarla. El mapa enlaza cada página. Cada gráfica tiene cuatro bloques: qué ves, cómo se lee, qué demuestra y qué te pueden preguntar. TIP marca lo que no sale de las diapositivas de la semana 3.

ÍNDICE · CADA COLOR ES UNA PARTE

El recorrido de la defensa



Qué es un M/M/1

λ Llegan clientes

En promedio llegan λ clientes por minuto, pero al azar (Poisson): el tiempo entre dos llegadas es exponencial, con media 1/λ.

> **Imaginalo:** 2 clientes por minuto, nunca a intervalos fijos.

μ Una caja los atiende

La cajera atiende μ clientes por minuto; cada cobro dura en promedio 1/μ, también exponencial. Una sola caja y fila FIFO.

> **Imaginalo:** μ = 3: un cobro dura 20 segundos en promedio.

ρ Qué tan ocupada está

ρ = λ/μ es la fracción del tiempo con la caja ocupada. Para que la cola no crezca sin límite tiene que cumplirse **λ < μ**.

Ojo · La guía escribe ρ invertido (μ/λ). Lo correcto es λ/μ.

Los tres escenarios: μ = 3.0 fijo y λ = 2.0 (ρ = 0.667, estable), 2.5 (ρ = 0.833, más carga) y 2.9 (ρ = 0.967, cerca de saturación).

A2

Las fórmulas, con el escenario 1

ρ Utilización

$$\rho = \frac{\lambda}{\mu} = \frac{2}{3} = 0.667$$

La caja está ocupada 2/3 del tiempo.

L Clientes en el sistema

$$L = \frac{\lambda}{\mu - \lambda} = \frac{2}{1} = 2$$

En la fila más el que está pagando.

Lq Clientes en la cola

$$L_q = \frac{\lambda^2}{\mu(\mu - \lambda)} = \frac{4}{3} = 1.33$$

Solo los que esperan.

W Tiempo en el sistema

$$W = \frac{1}{\mu - \lambda} = 1 \text{ min}$$

Desde que llega hasta que se va.

Wq Espera en cola

$$W_q = \frac{\lambda}{\mu(\mu - \lambda)} = 0.667 \text{ min}$$

Desde que llega hasta que lo atienden.

= Ley de Little

$$L = \lambda W \;\Rightarrow\; 2 = 2 \cdot 1$$

Une clientes con tiempos. También Lq = λWq.

La clave es la **holgura μ − λ**: está en el denominador. En E1 vale 1; en E3 vale 0.1, y por eso W pasa de 1 a 10 minutos. Si λ ≥ μ, las fórmulas no valen y el código no simula ese caso.

TEORÍA

A3 Si hay fórmulas, ¿para qué simular?

1 Las fórmulas son promedios

Dan el valor esperado **a largo plazo**. No dicen cuántos clientes hay a las 10:15 ni cuánto esperó cada uno.

2 La realidad es aleatoria

Llegadas y cobros al azar forman picos y rachas. En E1, Lq = 1.33, pero la cola llegó a 20 clientes en una jornada.

> **Imaginalo:** la fila del súper: en promedio corta, pero a veces se llena.

3 La simulación hace dos cosas

Valida: si los promedios simulados coinciden con las fórmulas, el modelo está bien. **Muestra** lo que el promedio esconde: picos, rachas y la mayoría sin esperar.

Frase para la defensa: "La teoría dice cuánto en promedio; la simulación muestra cómo se comporta el sistema minuto a minuto".

Cómo corre el programa

1 config.py
Los 3 escenarios (λ, μ), 20 000 min y semilla 42.

→

2 theory.py
Calcula las fórmulas; rechaza λ ≥ μ.

→

3 queue_system.py
SimPy simula cliente por cliente y anota cuándo llega, entra a la caja y se va.

→

4 analysis.py
Con esas anotaciones mide L, Lq, W, Wq y ρ simulados.

→

5 Vistas
Tabla en consola, 5 gráficas PNG y la ventana en vivo.

M model/ calcula

Fórmulas, simulación con SimPy y métricas simuladas. No sabe que existe una ventana.

V view/ dibuja

Tabla en consola, las 5 gráficas y la ventana en vivo. Nunca simula: muestra lo que recibe.

C controller/ conecta

Lee los argumentos, pide corridas al modelo y se las pasa a la vista.

> **Imaginalo:** un mozo: toma el pedido, va a la cocina y trae el plato.

25 tests comprueban las fórmulas, que la semilla repite la corrida, el orden FIFO, la convergencia y la ventana.

B2

CÓDIGO · MODEL/QUEUE_SYSTEM.PY

La caja en SimPy

```
env = simpy.Environment()
cashier = simpy.Resource(env, capacity=1)

def customer(record):
    with cashier.request() as request:
        yield request                # espera su turno
        record.service_start = env.now
        yield env.timeout(service_rng.exponential(1/μ))
        record.departure = env.now

def arrivals():
    while True:
        yield env.timeout(arrival_rng.exponential(1/λ))
        env.process(customer(nuevo_cliente))

env.process(arrivals()); env.run(until=20000)
```

1 Environment = el reloj

Lleva el tiempo de la simulación: **env.now** es el minuto actual.

2 Resource = la caja

capacity=1: atiende a uno; los demás esperan en su cola FIFO. Con capacity=2 serían dos cajas.

3 yield = esperar

Pausa al cliente hasta que la caja quede libre (**request**) o pasen t minutos (**timeout**).

4 exponential(1/λ)

NumPy pide la media, no la tasa. La **semilla** hace que la corrida se repita igual.

Resultados

```
$ python -m simulacion_ape --sin-animacion
Métrica      E1 teo   E1 sim   E2 teo   E2 sim   E3 teo   E3 sim
ρ             0.667    0.670    0.833    0.835    0.967    0.968
L             2.000    2.036    5.000    5.029   29.000   26.592
Lq            1.333    1.366    4.167    4.193   28.033   25.624
W  (min)      1.000    1.022    2.000    2.016   10.000    9.183
Wq (min)      0.667    0.685    1.667    1.681    9.667    8.849
Error máx.      2.8 %              0.9 %              8.6 %
```

E1 E2 Coinciden

Menos de 3 % de error. La simulación reproduce la teoría: **el modelo está bien**.

E3 ~8 % abajo

No es un error del código: cerca de ρ = 1 tarda muchísimo en estabilizarse (gráfica de convergencia).

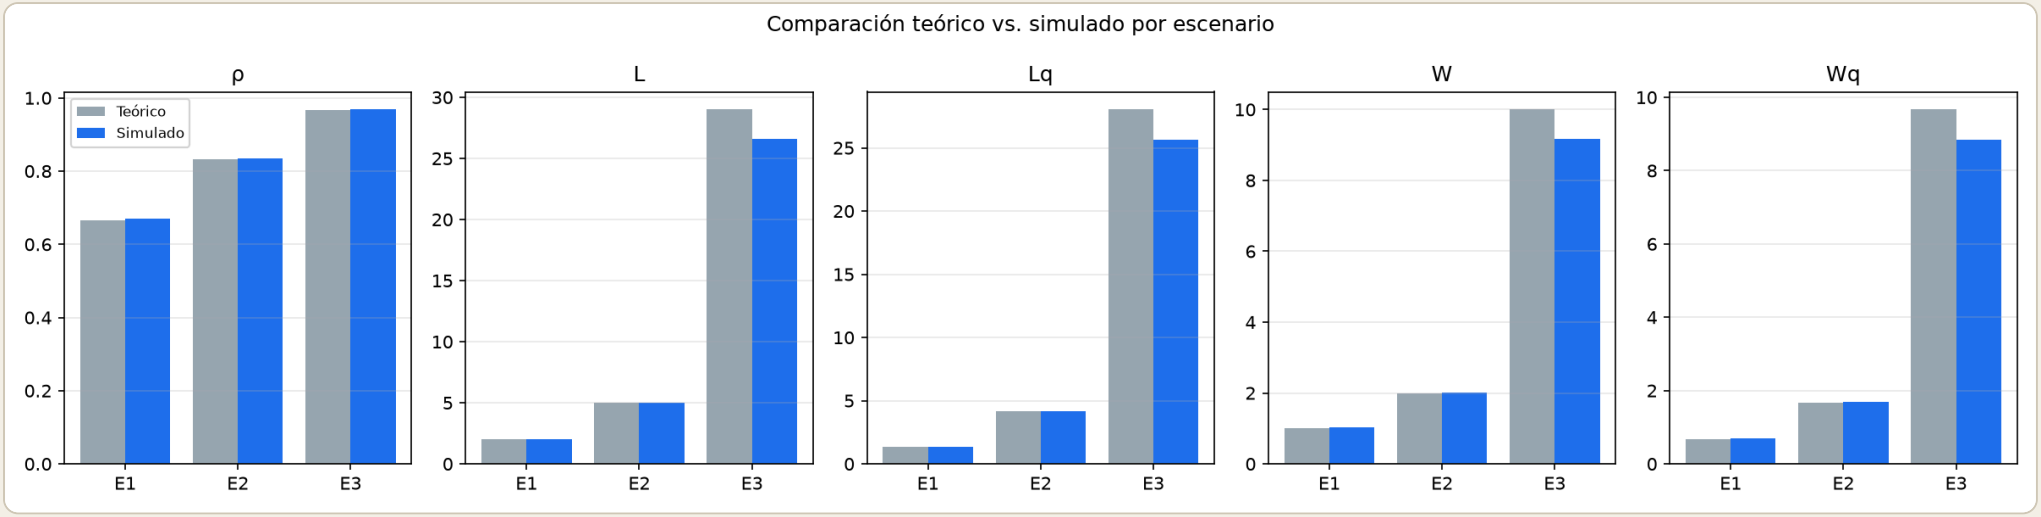
? La prueba

100 000 min: L = 30.3 (4 %). Semilla 1: L = 31.6, **arriba** de 29. Es azar, no un sesgo. TIP

GRÁFICAS · RESULTADOS/COMPARACION_TEORICO_SIMULADO.PNG

C1

Teórico vs. simulado



1 Qué ves

Una mini-gráfica por métrica (ρ, L, Lq, W, Wq). **Gris = fórmula, azul = simulación**, para E1, E2 y E3.

2 Cómo se lee

Si las dos barras son gemelas, la simulación reproduce la teoría.

3 Qué demuestra

E1 y E2 gemelas: modelo validado. ρ coincide siempre. En E3 la azul queda ~8 % más baja.

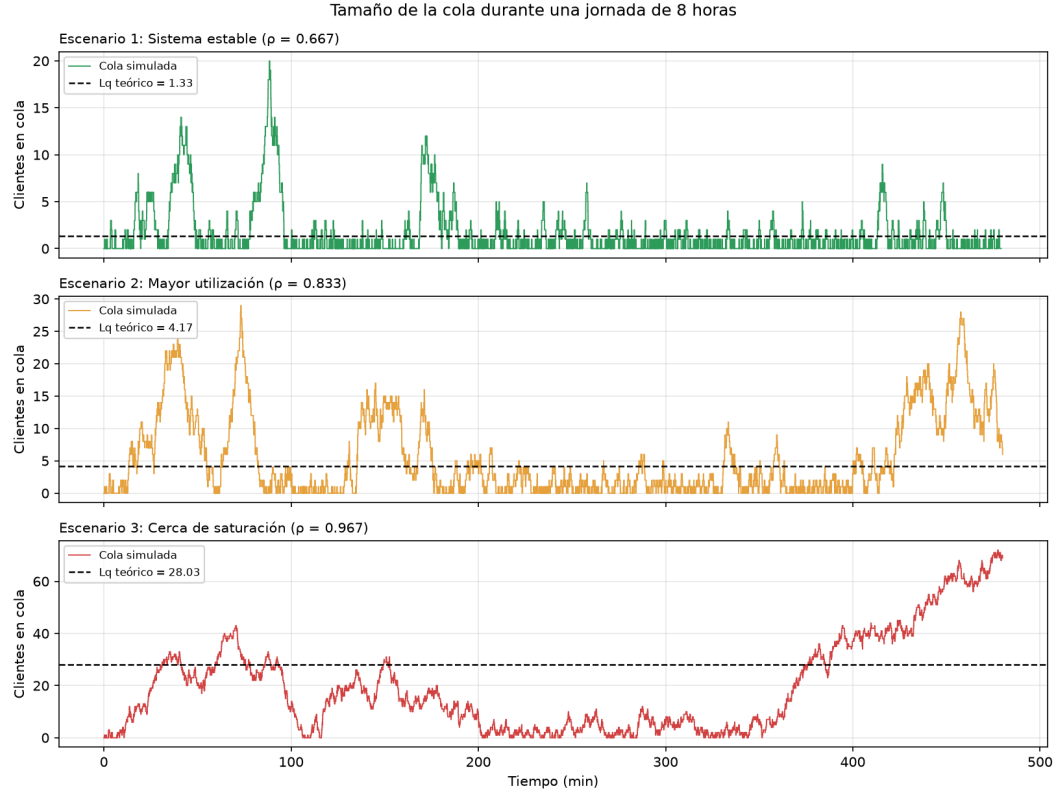
? Te preguntan

"¿Por qué E3 da menos?" Converge lento: con más tiempo se acerca, y con otra semilla queda arriba.

GRÁFICAS · RESULTADOS/COLA_EN_EL_TIEMPO.PNG

C2

La cola durante 8 horas



1 Qué ves

Clientes en la cola minuto a minuto, un panel por escenario. Punteada = **L_q teórico**.

2 Cómo se lee

Escalones: +1 cuando alguien llega, −1 cuando pasa a la caja.

3 Qué demuestra

E1: picos de 20 que se vacían rápido. E2: hasta 29. E3: no se vacía y termina con 69.

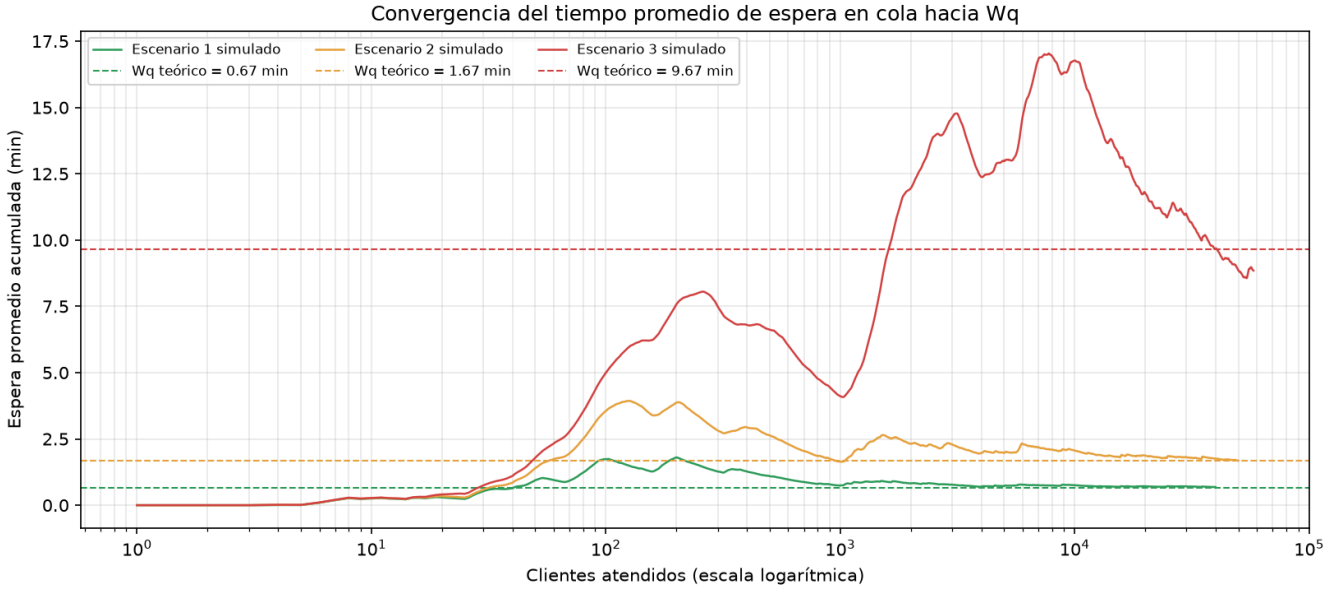
? Te preguntan

"¿Pico de 20 con L_q = 1.33? ¿Teoría mal?" No: L_q es un **promedio** a largo plazo, no un máximo.

GRÁFICAS · RESULTADOS/CONVERGENCIA_ESPERA.PNG

C3

La espera promedio va hacia W_q



1 Qué ves

Sólida: promedio de espera tras cada cliente. **Punteada** del mismo color: W_q teórico. Eje x logarítmico.

2 Cómo se lee

Cada sólida tiene que terminar pegada a su punteada.

3 Qué demuestra

Ley de los grandes números. E1 y E2 llegan; E3 sube a 17 y termina en 8.85 < 9.67: el 8 %.

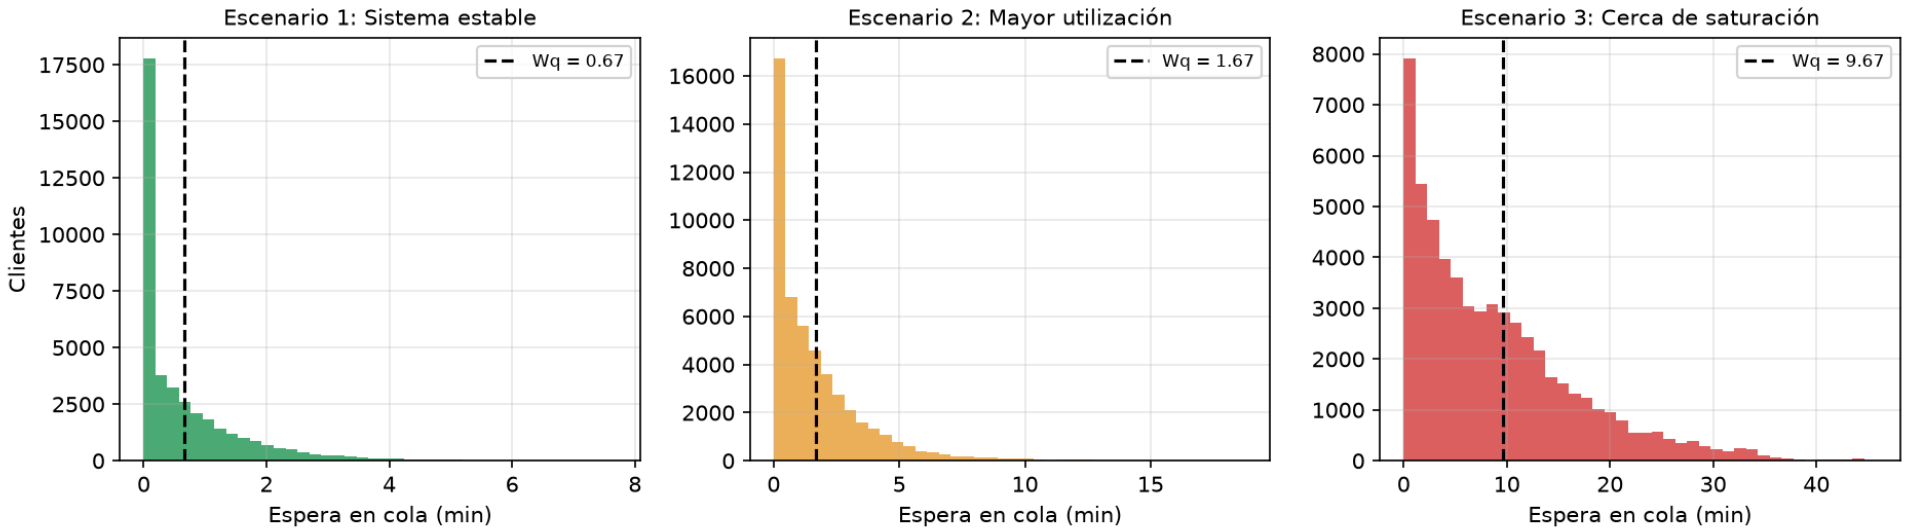
? Te preguntan

"¿Por qué arrancan en 0 y saltan?" Los primeros encuentran la caja libre, y con pocos datos un cliente mueve mucho el promedio.

GRÁFICAS · RESULTADOS/HISTOGRAMA_ESPERA.PNG

C4

¿Cuánto esperó cada cliente?



1 Qué ves

Cuántos clientes (alto de la barra) esperaron cada cantidad de minutos. Punteada = W_q.

2 Cómo se lee

La barra más alta está en 0; después baja, con una cola larga a la derecha.

3 Qué demuestra

El promedio no es lo típico: mediana 0.29 contra W_q 0.67 en E1. Pocos esperan mucho y suben el promedio.

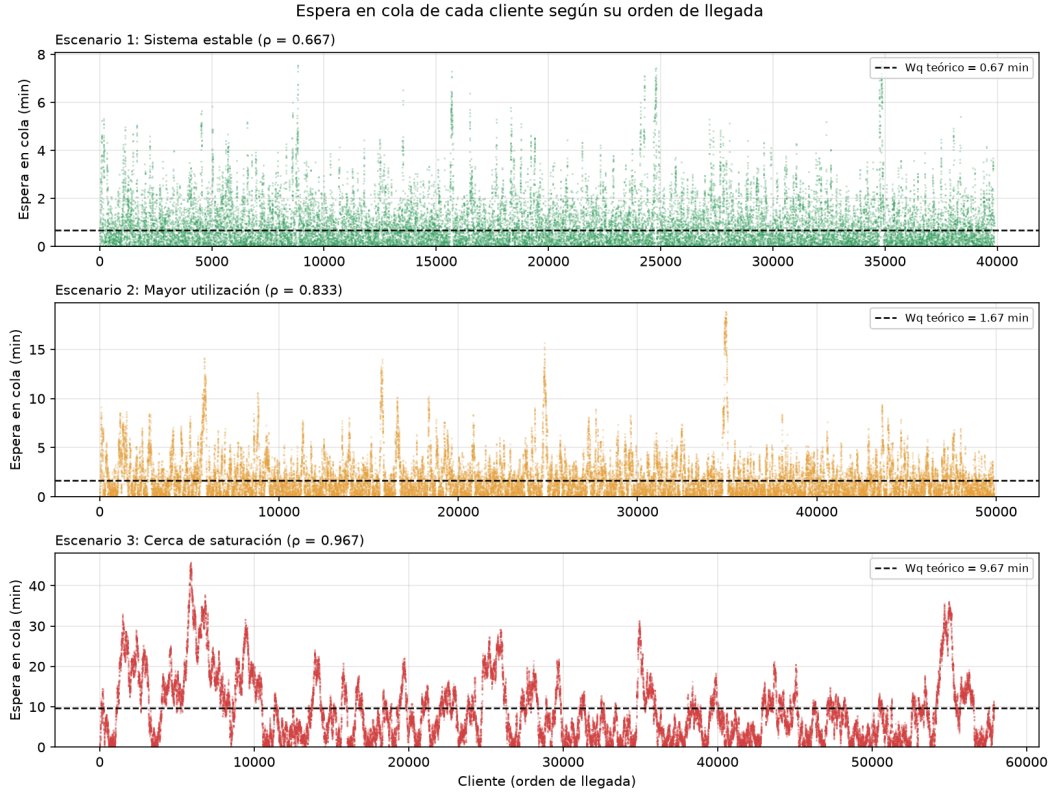
? Te preguntan

"¿Por qué tantos en 0?" Sin espera = 1 − ρ: 33.1 / 16.5 / 3.2 % simulado frente a 33.3 / 16.7 / 3.3 %.

GRÁFICAS · RESULTADOS/DISPERSION_ESPERA.PNG

C5

La espera de cada cliente



1 Qué ves

Cada punto es un cliente: x = orden de llegada, y = minutos de espera. Punteada = W_q. Cada panel tiene su escala.

2 Cómo se lee

Puntos sueltos = picos aislados. "Montañas" de puntos = rachas de muchos clientes seguidos esperando.

3 Qué demuestra

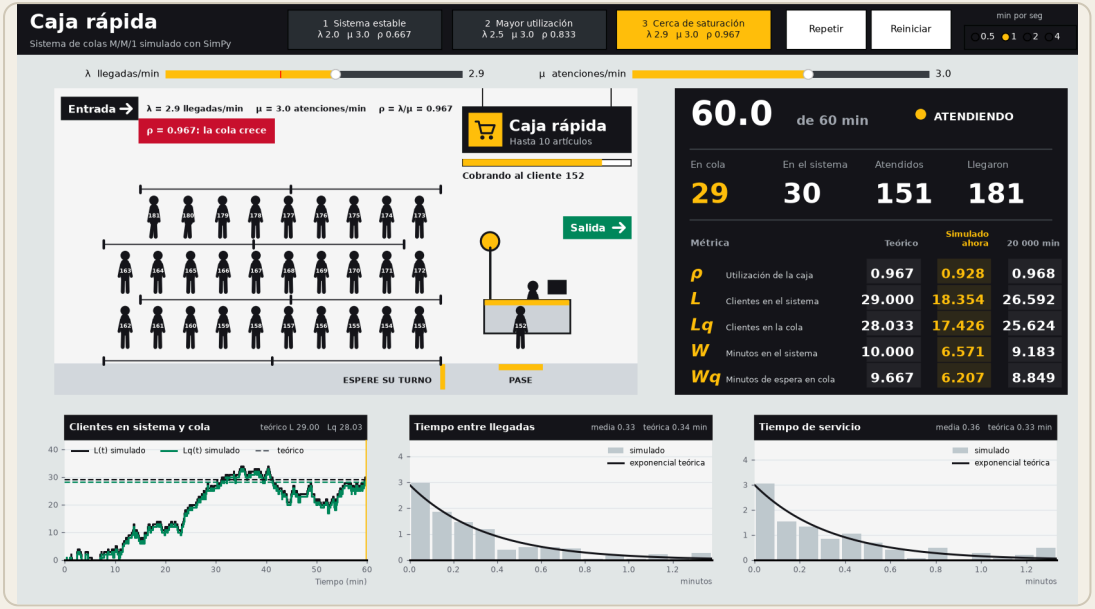
Máximo 7.7 / 18.8 / 45.8 min. En E3, hasta 2 636 clientes seguidos sobre W_q (E1: 124). Esas rachas frenan la convergencia.

? Te preguntan

"¿La guía la pedía?" Pide gráficas de la espera; la sumamos porque el docente mostró dispersión en clase.

D1

Ventana en vivo y demo



1 Qué muestra

El local con la fila, el tablero de métricas, 3 gráficas y deslizadores de λ y μ.

2 Por qué va fluida

Blitting: guarda el fondo y repinta solo lo que se mueve (~14 ms por cuadro).

3 Si λ ≥ μ

Avisa "Sistema inestable", oculta la teoría y la cola crece sin parar.

```
$ python -m simulacion_ape
  tabla + 5 PNG + ventana en vivo
$ python -m simulacion_ape --escenario 3
$ python -m simulacion_ape --llegada 1.5 --servicio 2
  λ y μ propios (van juntos)
$ python -m simulacion_ape --semilla 7
  otros números, mismas conclusiones
$ python -m simulacion_ape --tiempo 100000
  E3 se acerca más a la teoría
$ python -m pytest
  25 passed

# en la ventana
espacio   pausa
R         reinicia
1 2 3     escenarios
λ μ       deslizadores
```

AUTOEXAMEN · RESPONDÉ ANTES DE MIRAR

D2

Preguntas probables

01 ¿Por qué ρ = λ/μ y no μ/λ?

02 ¿Qué pasa si λ ≥ μ?

03 ¿Qué dice la ley de Little y cómo la comprobás?

04 ¿Por qué el escenario 3 tiene más error?

05 ¿Qué hace yield en un proceso de SimPy?

06 ¿Para qué sirve la semilla?

07 ¿Por qué exponential(1/λ) y no exponential(λ)?

08 ¿Dónde está el MVC y por qué la ventana no simula?

09 La cola llegó a 20 y Lq = 1.33: ¿la teoría está mal?

10 ¿Por qué la mayoría de los clientes no espera?

11 ¿Qué cambiarías para bajar el error?

12 ¿Cuál es el sistema real y qué supuestos hacen?

D2

Respuestas

01 Es la fracción del tiempo ocupada: lo que llega dividido entre lo que se puede atender. La guía lo escribe invertido. volver

02 La cola crece sin límite y no hay estado estable. La consola no lo simula; la ventana lo anima sin teoría. volver

03 L = λW y Lq = λWq. E1: L = 2 y λW = 2·1 = 2; simulado 2.036 ≈ 2·1.022. volver

04 Con ρ = 0.967 casi no hay holgura: hay rachas largas y el promedio converge lento. 20 000 min no alcanzan. volver

05 Pausa el proceso hasta que ocurre el evento: que la caja quede libre (request) o pasen t minutos (timeout). volver

06 Hace la corrida reproducible: mismos números, mismos resultados, y los tests comparan valores exactos. volver

07 NumPy recibe la media, no la tasa. La media entre llegadas es 1/λ y la del cobro 1/μ. volver

08 model/ calcula, view/ dibuja, controller/ conecta. La ventana pide corridas al controlador y nunca importa SimPy. volver

09 No. Lq es un promedio a largo plazo, no un máximo. Por el azar hay picos de 20 y ratos en 0; promediado da ≈ 1.33. volver

10 La caja está libre una fracción 1 − ρ del tiempo; quien llega en ese momento no espera. E1: 33 %. volver

11 Simular más tiempo (--tiempo) o varias réplicas con semillas distintas y promediar. TIP volver

12 Caja rápida de supermercado: llegadas de Poisson, cobro exponencial, una caja, fila FIFO y capacidad infinita. volver

CIERRE · SI SOLO TENÉS UN MINUTO

D3

Lo que tenés que poder decir

1. Modelamos una caja rápida como M/M/1: llegadas de Poisson, cobro exponencial, una caja FIFO.
2. SimPy simula cada cliente; el código es MVC: el modelo calcula, la vista dibuja.
3. E1 y E2 quedan a menos de 3 % de la teoría; E3, cerca de saturación, converge más lento.
4. Las gráficas muestran lo que el promedio esconde: picos, rachas y la mayoría sin esperar.
5. Semilla fija y 25 tests: los resultados se pueden repetir y verificar.