# Reporte Técnico de Actividades Práctico-Experimentales Nro. 003

## 1. Datos de Identificación del Estudiante y la Práctica

| | |
|---|---|
| **Nombre del estudiante(s)** | - Andrés Tapia<br>- Ariel González<br>- Gyna Yupanqui<br>- Alejandro Padilla |
| **Asignatura** | Simulación |
| **Ciclo** | 5 A |
| **Unidad** | 1 |
| **Resultado de aprendizaje de la unidad** | R1. Aplica análisis estadísticos de los datos de la Simulación para mejorar la calidad de los resultados, bajo los principios de solidaridad, transparencia, responsabilidad y honestidad. |
| **Práctica Nro.** | 003 |
| **Tipo** | Grupal |
| **Título de la Práctica** | Simulación de un sistema de líneas de espera M/M/1 mediante SimPy |
| **Nombre del Docente** | José O. Guamán Q. |
| **Fecha** | 16 de octubre de 2026 |

## 2. Objetivo(s) de la Práctica:

Simular un sistema de líneas de espera M/M/1 utilizando Python y SimPy, analizando el comportamiento de los clientes, la cola y el servidor.

- Implementar un modelo M/M/1 utilizando la biblioteca SimPy.
- Calcular las principales métricas teóricas del sistema de espera.
- Comparar los resultados teóricos con los obtenidos mediante la simulación.

## 3. Materiales y reactivos:

- Python 3.x.
- Biblioteca SimPy.
- NumPy.
- Matplotlib.
- Editor de código: Visual Studio Code, PyCharm o Jupyter Notebook.

## 4. Equipos y herramientas

- Computador.
- Procesador de 2 núcleos o superior.
- Mínimo 4 GB de RAM.
- Sistema operativo Linux o macOS.

## 5. Procedimiento / Metodología

### Inicio

- Se revisaron los conceptos básicos de teoría de colas y el funcionamiento del modelo M/M/1, destacando sus características clave: llegadas de clientes, tiempo de atención, un solo servidor y el orden de servicio basado en quién llegó primero (FIFO). También se definieron las tasas de llegada y de servicio y se estableció que, para que el sistema sea estable, debe cumplirse que $\lambda < \mu$.
- Después, se configuró el entorno de programación usando Python y las librerías SimPy, NumPy y Matplotlib, que son esenciales para crear la simulación, hacer los cálculos y mostrar los resultados de forma visual.

### Desarrollo

- Se implementó el modelo M/M/1 de líneas de espera con la biblioteca SimPy, estableciendo cómo llegaban los clientes y cómo se atendían mediante un solo servidor. Para simular el comportamiento aleatorio del sistema, se emplearon distribuciones exponenciales para los tiempos entre llegadas y los tiempos de atención.
- Luego, se calcularon las métricas teóricas del sistema: la utilización del servidor, el número promedio de clientes en el sistema, el número promedio de clientes en la cola, el tiempo promedio de permanencia en el sistema y el tiempo promedio de espera en la cola, con las fórmulas de la Tabla 1, válidas solo cuando $\lambda < \mu$.

Tabla 1. Fórmulas del modelo M/M/1.

| Métrica | Fórmula | Significado |
|---|---|---|
| **$\rho$** | $\rho = \lambda / \mu$ | Fracción del tiempo que el servidor está ocupado |
| **$L$** | $L = \lambda / (\mu - \lambda)$ | Clientes promedio en el sistema |
| **$L_q$** | $L_q = \lambda^2 / [\mu (\mu - \lambda)]$ | Clientes promedio en la cola |
| **$W$** | $W = 1 / (\mu - \lambda)$ | Tiempo promedio en el sistema |
| **$W_q$** | $W_q = \lambda / [\mu (\mu - \lambda)]$ | Tiempo promedio de espera en la cola |

Por ejemplo, en el escenario 1 ($\lambda = 2.0$, $\mu = 3.0$): $\rho = 2/3 = 0.667$, $L = 2/(3 - 2) = 2$ clientes, $L_q = 4/(3 \cdot 1) = 1.333$ clientes, $W = 1/(3 - 2) = 1$ minuto y $W_q = 2/(3 \cdot 1) = 0.667$ minutos. Además, se cumple la ley de Little: $L = \lambda \cdot W$ y $L_q = \lambda \cdot W_q$.

- A continuación, se ejecutaron los tres escenarios propuestos ($\lambda = 2.0$, 2.5 y 2.9 clientes/min, con $\mu = 3.0$ clientes/min) durante 20 000 minutos simulados y con semilla 42, para estudiar el comportamiento de los clientes, sus tiempos de espera y la longitud de la cola. Los resultados se mostraron en gráficos y se compararon con los valores teóricos.

### Cierre

- Finalmente, se revisaron los resultados de cada escenario, enfocándose en cómo cambian el tiempo de espera y el tamaño de la cola cuando la tasa de llegada se acerca a la tasa de servicio.

- Se destacó la importancia de equilibrar estas tasas para evitar que el servidor se sature.
- Al final, se compararon los resultados de la simulación con los cálculos teóricos, teniendo en cuenta que pueden surgir diferencias por la naturaleza aleatoria de los procesos y la duración limitada de la simulación. De esta forma, se analizó el comportamiento del modelo M/M/1 y su aplicabilidad para estudiar y comprender los sistemas de colas.

## 6. Resultados

Las figuras 1 a 3 muestran la ventana en vivo de la simulación, construida con Matplotlib, en cada escenario. La columna «Simulado ahora» corresponde a los 60 minutos de la animación; los valores que se comparan con la teoría son los de la columna «20 000 min».

### 1. Sistema estable




Figura 1. Escenario 1: sistema estable (λ = 2.0, μ = 3.0, ρ = 0.667).

La tasa de llegada es más baja que la tasa con la que el servidor atiende, por lo que no se forma una cola muy larga y el sistema trabaja de forma estable.

## 2. Mayor utilización

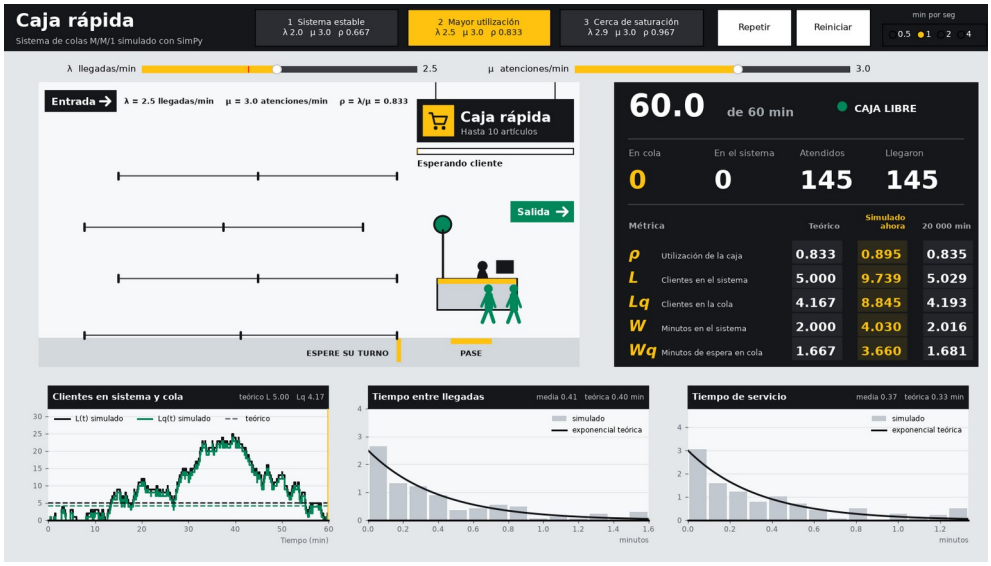



Figura 2. Escenario 2: mayor utilización (λ = 2.5, μ = 3.0, ρ = 0.833).

Al aumentar la tasa de llegada, el servidor maneja más carga, lo que hace que aumente el número de clientes esperando y que tarden más en ser atendidos. Esto muestra que la cola se hace más larga cuando el servidor se aproxima a su capacidad máxima.

## 3. Cerca de saturación

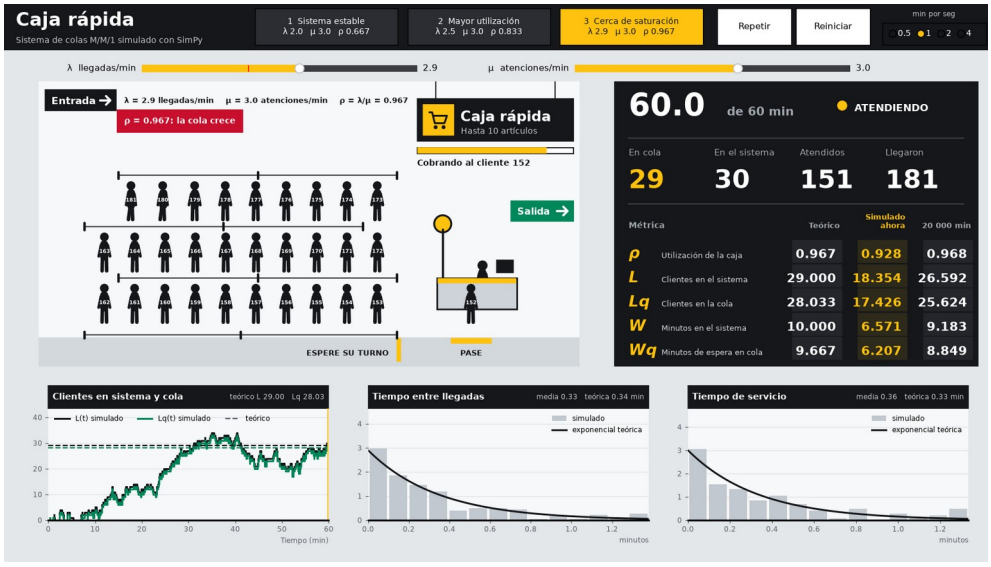



Figura 3. Escenario 3: cerca de saturación (λ = 2.9, μ = 3.0, ρ = 0.967).

La tasa de llegada se acerca a la tasa de servicio, lo que genera una gran acumulación de clientes y un incremento en los tiempos de espera. El servidor funciona prácticamente sin parar, lo que muestra el peligro de que el sistema se sobrecargue.

### Comparación entre resultados teóricos y simulados

La Tabla 2 resume la corrida de 20 000 minutos con semilla 42 de cada escenario. Entre paréntesis se indica el error relativo, calculado como |simulado − teórico| / teórico.

Tabla 2. Valores teóricos / simulados y error relativo por escenario.

| Métrica | Escenario 1 (ρ = 0.667) | Escenario 2 (ρ = 0.833) | Escenario 3 (ρ = 0.967) |
|---|---|---|---|
| **ρ** | 0.667 / 0.670 (0.5 %) | 0.833 / 0.835 (0.2 %) | 0.967 / 0.968 (0.2 %) |
| **L** | 2.000 / 2.036 (1.8 %) | 5.000 / 5.029 (0.6 %) | 29.000 / 26.592 (8.3 %) |
| **$L_q$** | 1.333 / 1.366 (2.5 %) | 4.167 / 4.193 (0.6 %) | 28.033 / 25.624 (8.6 %) |
| **W (min)** | 1.000 / 1.022 (2.2 %) | 2.000 / 2.016 (0.8 %) | 10.000 / 9.183 (8.2 %) |
| **$W_q$ (min)** | 0.667 / 0.685 (2.8 %) | 1.667 / 1.681 (0.9 %) | 9.667 / 8.849 (8.5 %) |

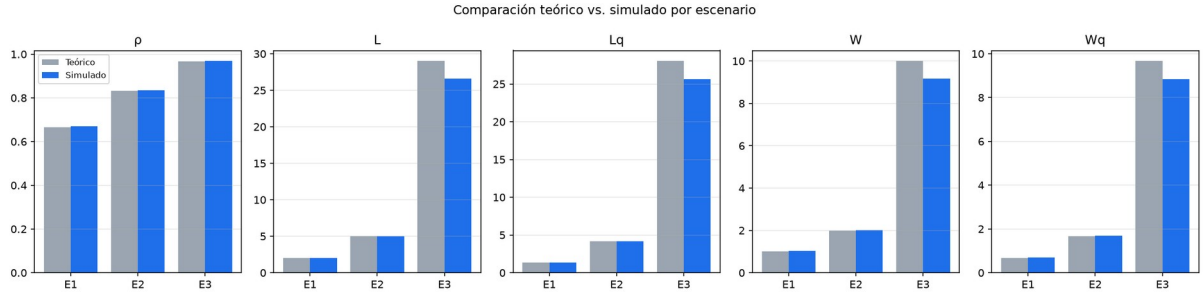



Figura 4. Métricas teóricas y simuladas por escenario.

De la Tabla 2 y la Figura 4 se desprenden tres observaciones:

- **La utilización es la métrica más precisa** en los tres escenarios (error de 0.5 % o menos), porque solo mide la fracción de tiempo en que la caja está ocupada y se estabiliza pronto.
- **En los escenarios 1 y 2 la simulación reproduce la teoría**, con errores entre 0.6 % y 2.8 % en las métricas de la cola. Esto valida tanto el modelo como su implementación.
- **En el escenario 3 las métricas de la cola se alejan entre 8.2 % y 8.6 %**, por encima del 5 % que la clase propone como criterio de validación. No se trata de un error del código, sino de que el promedio simulado todavía no se estabiliza, como muestra la Figura 5; para cumplir el criterio habría que usar varias réplicas y descartar el periodo de calentamiento.

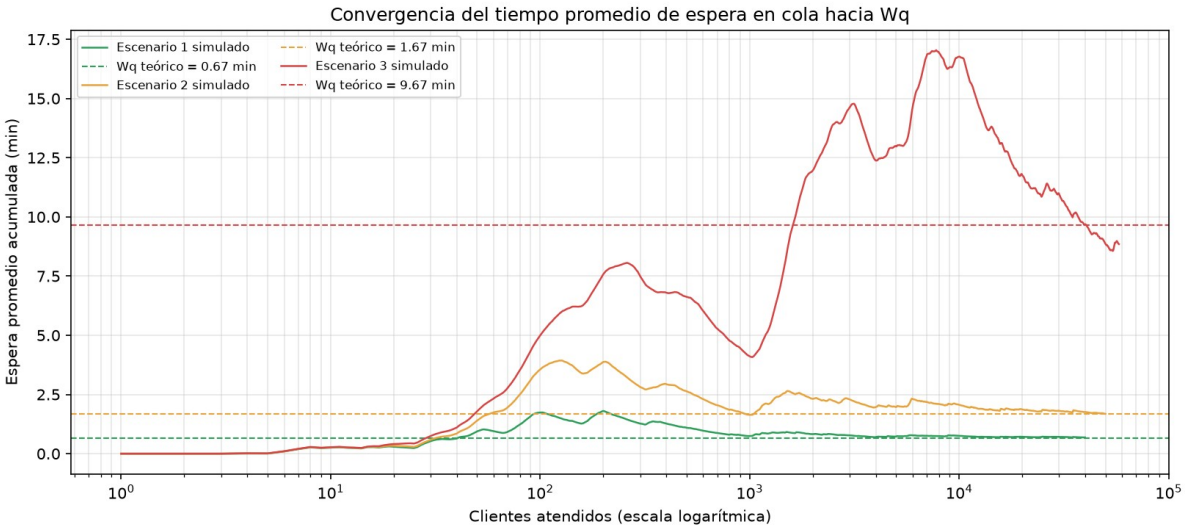



Figura 5. Promedio acumulado de la espera en cola frente al número de clientes atendidos.

La Figura 5 muestra cómo evoluciona el promedio de la espera en cola a medida que se atienden clientes. En los escenarios 1 y 2 la curva se acerca a $W_q$ después de unos pocos miles de clientes y ya no se separa. En el escenario 3, en cambio, sube hasta cerca de 17 minutos y después de casi 58 000 clientes todavía cruza el valor teórico de 9.67 minutos: cerca de la saturación, la simulación necesita muchísimo más tiempo para estabilizarse.

Como verificación interna, los resultados simulados cumplen la ley de Little: $\lambda \cdot W$ da 2.044, 5.040 y 26.631 clientes, frente a un L simulado de 2.036, 5.029 y 26.592. La diferencia es menor al 0.5 % en los tres escenarios, lo que indica que el modelo registra de forma coherente las llegadas, las esperas y las salidas de los clientes.

## Análisis del comportamiento del sistema para los tres escenarios propuestos

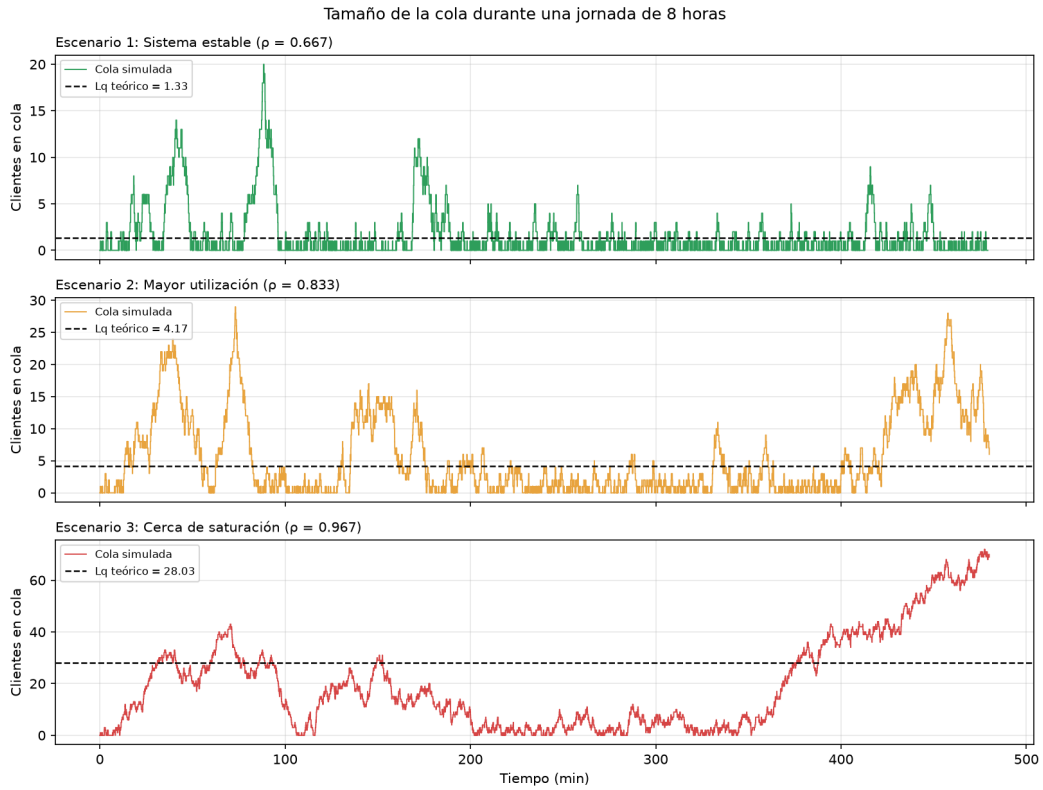



Figura 6. Tamaño de la cola durante una jornada de 8 horas en cada escenario.

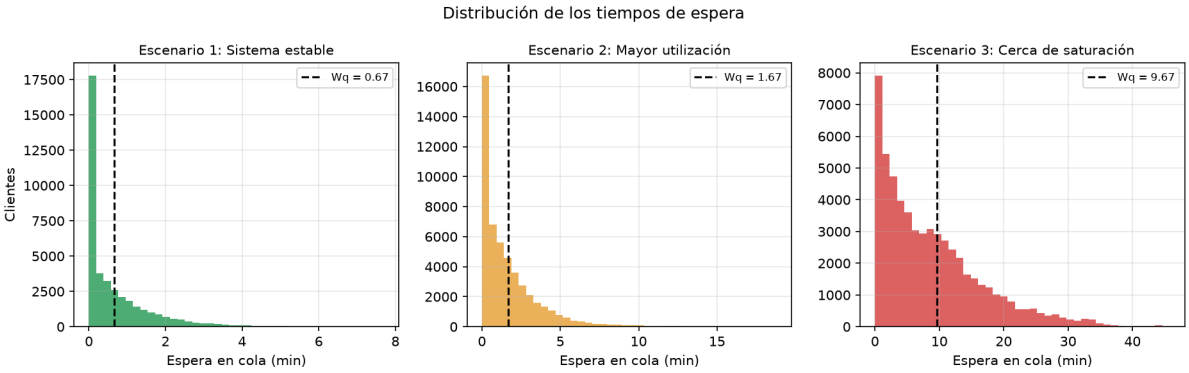



Figura 7. Distribución de los tiempos de espera en cola de los clientes simulados.

- **Escenario 1 (ρ = 0.667):** la caja está libre un tercio del tiempo, por lo que uno de cada tres clientes no espera nada. La cola vuelve a cero con frecuencia y sus picos, de hasta 20 clientes en la jornada de la Figura 6, desaparecen en pocos minutos. Aun así, de cada minuto que un cliente pasa en el sistema, 0.667 minutos los pasa esperando.
- **Escenario 2 (ρ = 0.833):** λ aumenta 25 % respecto al escenario 1, pero L se multiplica por 2.5 y W por 2. Con ρ = 0.833 el sistema ya supera el punto de operación seguro de ρ ≤ 0.8: los episodios de cola larga duran más, y la cola llega a 29 clientes durante la jornada.
- **Escenario 3 (ρ = 0.967):** λ aumenta 45 % respecto al escenario 1, pero W pasa de 1 a 10 minutos y L de 2 a 29 clientes. La cola ya no se vacía con facilidad: la jornada

simulada termina con cerca de 70 clientes en espera, y en la Figura 7 algunos clientes esperan más de 40 minutos. Solo el 3.3 % de los clientes encuentra la caja libre.

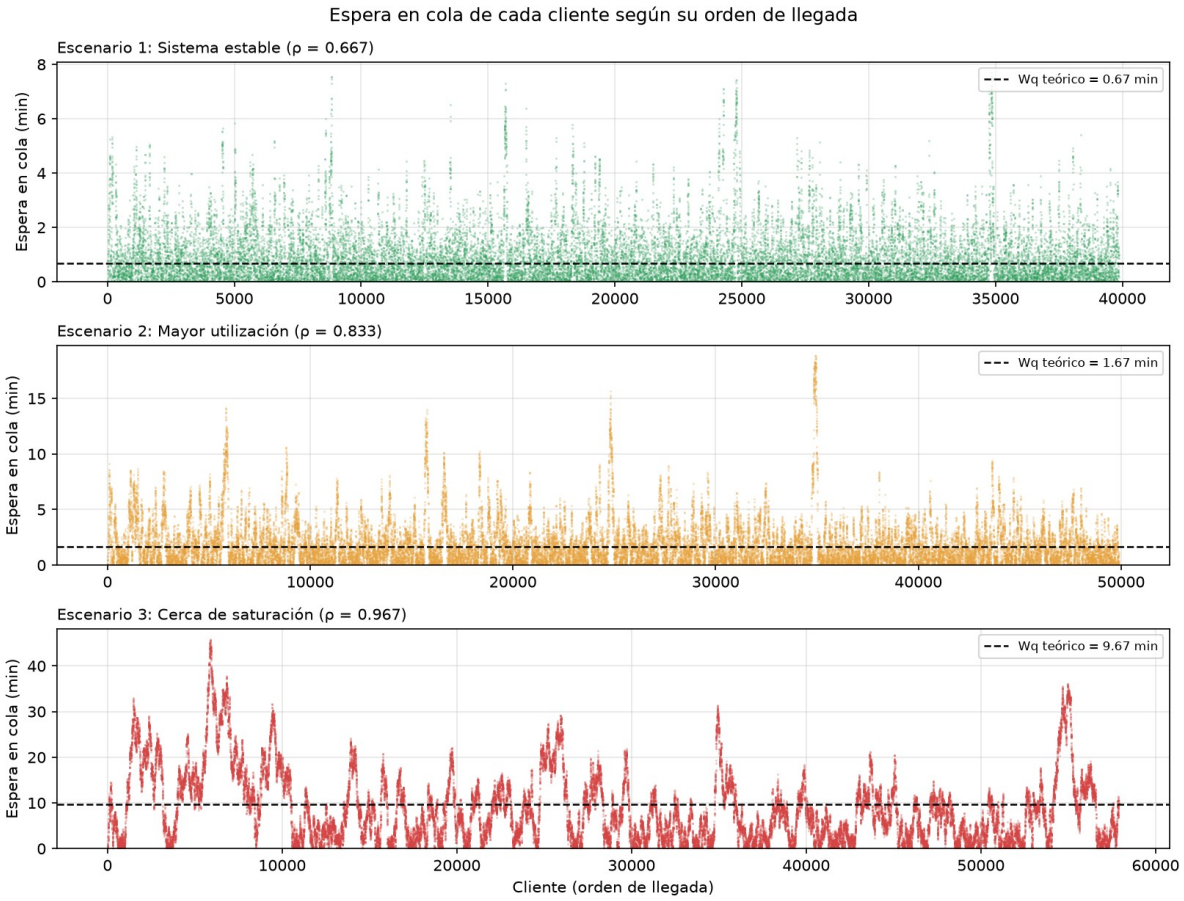



Figura 8. Espera en cola de cada cliente según su orden de llegada; la línea punteada es $W_q$ teórico.

La Figura 8 muestra la espera de cada cliente en el orden en que llegó. En el escenario 1 las esperas no pasan de 7.7 minutos y los picos son aislados; en el escenario 2 llegan a 18.8 minutos. En el escenario 3 las esperas forman rachas largas que llegan a 45.8 minutos, y hasta 2 636 clientes seguidos esperan más que $W_q$. Esas rachas son la razón por la que el promedio de la Figura 5 tarda tanto en converger.

El crecimiento no es lineal porque $W = 1/(\mu - \lambda)$ depende de la holgura $\mu - \lambda$, que en los tres escenarios vale 1.0, 0.5 y 0.1 clientes/min. Reducir esa holgura a la décima parte multiplica por diez el tiempo que el cliente pasa en el sistema. Para la caja rápida, esto significa que con ρ cercano a 1 una mejora pequeña no alcanza: habría que abrir una segunda caja o reducir el tiempo de atención.

**Repositorio en GitHub:**
https://github.com/AlejandroTatum/simulacion-unl/tree/main/unidad-1/ape-3-mm1

## 7. Preguntas de Control

- **¿Qué representa el modelo M/M/1?**

En la notación de Kendall A/B/c/K/N/D, el M/M/1 corresponde a M/M/1/∞/∞/FIFO: llegadas de Poisson (A = M, de Markov, sin memoria), servicio exponencial (B = M), un solo servidor (c = 1), capacidad ilimitada (K = ∞), población infinita (N = ∞) y disciplina FIFO. Es el caso más simple de la teoría de colas: sus supuestos son restrictivos, pero permiten fórmulas cerradas para todas las métricas. En esta práctica representa la caja rápida de un supermercado con una sola cajera.

- **¿Qué representan λ y μ?**

λ es la tasa de llegada, es decir, los clientes que llegan por unidad de tiempo, y determina la demanda del sistema; μ es la tasa de servicio, los clientes que el servidor atiende por unidad de tiempo, y determina su capacidad. En los escenarios, λ vale 2.0, 2.5 y 2.9 clientes/min y μ = 3.0 clientes/min. Sus inversos son el tiempo medio entre llegadas (E[T] = 1/λ) y el tiempo medio de atención: con μ = 3.0, cada atención dura en promedio 1/3 de minuto (20 segundos).

- **¿Por qué debe cumplirse λ < μ para que el sistema sea estable?**

Porque la condición de estabilidad es $\rho = \lambda/\mu < 1$, que equivale a $\lambda < \mu$. Si $\rho \geq 1$ llegan, en promedio, al menos tantos clientes como los que el servidor puede atender, las colas crecen sin límite y ni las fórmulas del M/M/1 ni la ley de Little son válidas: todas las fórmulas tienen $\mu - \lambda$ en el denominador. Por eso el código rechaza esos casos con un error antes de calcular.

- **¿Qué significa la utilización ρ?**

$\rho = \lambda/\mu$ es la fracción del tiempo en que el servidor está ocupado, y $P_0 = 1 - \rho$ es la probabilidad de que el sistema esté vacío. En el escenario 1, $\rho = 0.667$ significa que la caja está ocupada dos tercios del tiempo y libre el tercio restante ($P_0 = 0.333$); la simulación midió 0.670. Como referencia práctica se recomienda operar con $\rho \leq 0.8$, valor que los escenarios 2 y 3 superan.

- **¿Cuál es la diferencia entre W y $W_q$?**

W es el tiempo esperado total en el sistema (espera más servicio) y $W_q$ es el tiempo esperado en la cola antes de iniciar el servicio. Se diferencian justamente en el tiempo medio de servicio: $W = W_q + 1/\mu$. En el escenario 1, 1.000 = 0.667 + 0.333 minutos.

- **¿Cuál es la diferencia entre L y $L_q$?**

L es el número esperado de clientes en el sistema (cola más servicio) y $L_q$ el número esperado de clientes que esperan a ser atendidos. Ambas se relacionan con los tiempos por la ley de Little, $L = \lambda W$ y $L_q = \lambda W_q$; en el escenario 1, $L = 2.0 \cdot 1.000 = 2.000$ y $L_q = 2.0 \cdot 0.667 = 1.333$.

- **¿Por qué SimPy utiliza una distribución exponencial para generar los tiempos?**

Porque en un proceso de Poisson con tasa λ el tiempo entre eventos sigue una distribución exponencial de media 1/λ (y varianza $1/\lambda^2$). Ese proceso supone eventos independientes, una probabilidad de llegada $\lambda\Delta t$ en un intervalo corto y falta de

memoria: el tiempo hasta la próxima llegada no depende del tiempo transcurrido desde la anterior. El servicio del M/M/1 también es exponencial. En el código, los tiempos se generan con la exponencial de NumPy y SimPy avanza el reloj con env.timeout; los histogramas de la ventana en vivo confirman que siguen la curva teórica.

- **¿Qué sucede con la cola cuando λ se aproxima a μ?**

Ocurre la inestabilidad por congestión: cuando ρ → 1, todas las métricas tienden a infinito, por ejemplo $L = \rho/(1 - \rho)$. Aunque el servidor parezca alcanzar a atender, la varianza de las distribuciones exponenciales provoca momentos en que llegan muchos clientes seguidos y el servidor ya no recupera el retraso. En la práctica se observó en el escenario 3: con ρ = 0.967, L = 29 clientes y W = 10 minutos, frente a 2 clientes y 1 minuto con ρ = 0.667.

- **¿Por qué los resultados simulados pueden ser diferentes de los resultados teóricos?**

Porque las fórmulas dan valores esperados del estado estable, mientras que la simulación estima promedios a partir de una muestra aleatoria finita. Según el criterio de validación de la clase, los errores deben quedar por debajo del 5 % con 30 réplicas de 10 000 minutos; si no, hay que revisar el periodo de calentamiento (warm-up), el número de réplicas y el cálculo de las áreas. En esta práctica se usó una sola réplica de 20 000 minutos sin eliminar el calentamiento: los escenarios 1 y 2 cumplen el criterio, pero el escenario 3 llega a 8.6 %, porque cerca de ρ = 1 la varianza es mayor.

- **¿Qué ocurriría si λ fuera mayor que μ?**

Se tendría ρ > 1 y el sistema sería inestable: las fórmulas del M/M/1 no aplican y la cola crece sin límite, en promedio a razón de λ − μ clientes por unidad de tiempo. Con λ = 3.5 y μ = 3.0, por ejemplo, se acumularían unos 0.5 clientes por minuto, alrededor de 240 al final de una jornada de 8 horas. Solo se puede estabilizar aumentando la capacidad, por ejemplo agregando servidores.

## 8. Conclusiones

- Se implementó el modelo M/M/1 de la caja rápida en SimPy con semilla configurable. Con 20 000 minutos simulados, los resultados coinciden con la teoría con errores menores al 3 % en los escenarios 1 y 2, lo que valida el modelo y su implementación.
- La utilización es la métrica que mejor coincide con la teoría (0.5 % de error o menos), mientras que las métricas de la cola son las más sensibles a la aleatoriedad, en especial cerca de la saturación, donde el error llega a 8.6 %.
- El desempeño del sistema depende de la holgura μ − λ y no de λ por sí sola: al pasar de ρ = 0.667 a ρ = 0.967, λ aumenta 45 %, pero el tiempo en el sistema se multiplica por diez.
- Cerca de la saturación, la simulación necesita mucho más tiempo para estabilizarse, por lo que la duración de la corrida debe elegirse de acuerdo con ρ antes de comparar con la teoría.

## 9. Declaración de IA

En esta práctica utilicé un agente de programación basado en el modelo Claude de Anthropic como herramienta de apoyo para estructurar el código en SimPy, generar las gráficas y la ventana en vivo de Matplotlib, revisar el informe grupal y redactar borradores de esta sección individual. Las decisiones sobre el modelo, los escenarios, la semilla y el formato las tomé junto con el grupo; verifiqué cada resultado ejecutando el código y comparándolo con las fórmulas teóricas, y revisé y ajusté el texto antes de entregarlo.

## 10. Bibliografía

Guamán, J. O. (2026). *Teoría de colas: Modelo M/M/1. Análisis matemático de sistemas de espera* [Diapositivas de clase, semana 3]. Asignatura Simulación, Carrera de Computación, Universidad Nacional de Loja.